

Φάση 2 – Σημασιολογική ανάκτηση

Σε αυτή την φάση θα υλοποιήσουμε ένα σύστημα σημασιολογικής ανάκτησης πληροφορίας πάνω στην συλλογή IR2025, χρησιμοποιώντας πυκνές διανυσματικές αναπαραστάσεις (embeddings) ολόκληρων κειμένων και ερωτημάτων με την αποδοτική αναζήτηση με την βιβλιοθήκη FAISS.

Τα embeddings αυτά παράγονται από προεκπαιδευμένα νευρωνικά μοντέλα τύπου transformers, τα οποία μπορούν να συλλαμβάνουν σημασιολογικές σχέσεις μεταξύ λέξεων και προτάσεων χωρίς να υπάρχει ακριβής ταύτιση λέξεων.

Για την αναζήτηση των πιο συναφών κειμένων θα χρησιμοποιήσουμε την βιβλιοθήκη FAISS, η οποία επιτρέπει γρήγορη εύρεση των κ πλησιέστερων γειτόνων με βάση την συνημιτονοειδή ομοιότητα.

1. Προεπεξεργαστείτε τη συλλογή κειμένων IR2025 (αρχείο documents.csv) προκειμένου να είναι σε κατάλληλη μορφή για να δοθεί ως είσοδος σε κάποιο μοντέλο transformers.

Αρχίζοντας την διαδικασία της προεπεξεργασίας βλέπουμε ότι η συλλογή κειμένων IR2025 βρίσκεται σε αρχείο csv οπότε εξάγουμε τα δεδομένα σε λίστες ώστε να είναι σε κατάλληλη μορφή για είσοδο σε μοντέλο τύπου transformers. Φτιάχνουμε μία λίστα χαρακτήρων με τα κείμενα, όπου μία συμβολοσειρά είναι το περιεχόμενο ενός κειμένου (text), και μία λίστα για τα αναγνωριστικά, όπου κάθε αντικείμενο της είναι ένα μοναδικό αναγνωριστικό κειμένου (doc_id).

	ID	Text
1	193157	IC in its implementation, is explained below"
2	193158	ementation of the ERC under Horizon 2020.
3	193159	y in the Consortium activities are envisaged.
4	193160	loping and operating the proposed services.
5	193161	Copernicus Service infrastructure in Europe.
6	193162	re stock assessment, and seabed mapping.
7	193163	novative products that reflect societal needs.

csv to lists

```
for i in range(3):
    print("Doc ID:", doc_ids[i])
    print("Text:", texts[i][:200], "...\\n")
```

Doc ID: 193157
Text: Support towards the Europe PMC initiative-Contribution for 2014-2016: "The proposed action will provide continued support t o the European Research Council (ERC) in the implementation of i ts Open Acces ...

Doc ID: 193158
Text: Support to the Vice-Presidents of the ERC Scientific Council 2014: The proposed Action will provide the necessary support to the Vice-Presidents of the European Research Council Scientific Council (ER ...

Doc ID: 193159
Text: Implementation of activities described in the Roadmap to Fusion during Horizon 2020 through a Joint programme of the members of the EUROfusion consortium: A Roadmap to the realization of fusion energy ...

2. Χρησιμοποιήστε ένα προεκπαιδευμένο μοντέλο από τη βιβλιοθήκη transformers (π.χ. DistilBERT, sentence-transformers, all-MiniLM-L6-v2 ή παρόμοιο) για να μετατρέψετε κάθε κείμενο της συλλογής και κάθε ερώτημα σε πυκνά διανύσματα – ενθέσεις (embeddings). Φροντίστε τα embeddings να έχουν κοινή διάσταση (π.χ. 384 ή 768). Αποθηκεύστε τα διανύσματα για επαναχρησιμοποίηση.

Διαλέγουμε ένα προεκπαιδευμένο μοντέλο από τη βιβλιοθήκη transformers για την μετατροπή των κειμένων της συλλογής και των ερωτημάτων σε πυκνά διανύσματα σταθερής διάστασης.

Η συλλογή κειμένων IR2025 είναι μεγάλη με 18.316 κείμενα οπότε η χρήση του μοντέλου BERT ή DistilBERT δεν είναι καθόλου αποδοτική αφού είναι αρκετά αργά σε ταχύτητα. Συγκεκριμένα για την αναπαράσταση των 18.316 κειμένων θα χρειαστεί τουλάχιστον 1 ώρα.

Επομένως επιλέγουμε το μοντέλο all-MiniLM-L6-v2, το οποίο είναι ελαφρύ και αποδοτικό για την σημασιολογική αναπαράσταση. Παράγει embeddings διάστασης 384.

Υπολογίζεται ένα embedding για κάθε κείμενο χρησιμοποιώντας την μέθοδο encode του μοντέλου. Κάνει batch processing σε μέγεθος 32 παρτίδων ώστε να μειωθεί ο συνολικός χρόνος εκτέλεσης αξιοποιώντας την μνήμη του συστήματός μας. Γίνεται κανονικοποίηση των embeddings ώστε όλα τα διανύσματα να έχουν μοναδιαίο μήκος και να χρησιμοποιήσουμε στην συνέχεια την συνημιτονοειδή ομοιότητα.

4. Για κάθε ερώτημα: α) υπολογίστε το *embedding* του ερωτήματος χρησιμοποιώντας το μοντέλο *transformers* από το βήμα 2, β) αναζητήστε στο ευρετήριο FAISS τα *k* πιο κοντινά κείμενα, για *k* = 20, 30, 50, βάσει συνημιτονοειδούς ομοιότητας (*cosine similarity*) ή L2 απόστασης, γ) επιστρέψτε τα αποτελέσματα ταξινομημένα κατά φθίνουσα ομοιότητα.

Αρχικά, φτιάχνουμε την μέθοδο `semantic_search` που θα κάνει την σημασιολογική αναζήτηση των *k* συναφών κειμένων στο ερώτημα `query` που λαμβάνει σαν είσοδο. Υπολογίζει το *embedding* του ερωτήματος όπως προηγουμένως με το ίδιο μοντέλο το `all-MiniLM-L6-v2` και κανονικοποίηση. Εκτελεί την αναζήτηση στο ευρετήριο που φτιάξαμε πριν βάσει του διανύσματος του ερωτήματος και το πλήθος *k* των ανακτηθέντων εγγράφων. Το ευρετήριο `IndexFlatIP` επιστρέφει τα *k* αποτελέσματα σε φθίνουσα σειρά βάσει του σκορ ομοιότητας. . Επιστρέφει τα ανακτηθέντα συναφή κείμενα και τα *id* τους.

Για κάθε *k* πιο κοντινά κείμενα όπου *k*=20, 30, 50 εκτελείται η μέθοδος `queries_run` η οποία παίρνει ως είσοδο το αρχείο με όλα τα ερωτήματα. Για καθένα από τα ερωτήματα βρίσκει το *id* και το περιεχόμενό του και καλεί την συνάρτηση `semantic_search` για να πάρει τα *k* πιο σχετικά έγγραφα και τα σκορ ομοιότητάς τους. Έπειτα, αποθηκεύει το κάθε αποτέλεσμα σε λίστα με μορφή κατάλληλη για το εργαλείο αξιολόγησης `trec_eval`.

```
# saving the results to later put in files
results_20 = queries_run(queries, k=20)
print(results_20)
results_30 = queries_run(queries, k=30)
results_50 = queries_run(queries, k=50)
```

```
[{'query_id': 'Q01', 'doc_id': 193378, 'rank': 1, 'score': 0.9309734106063843}, {'query_id': 'Q01', 'doc_id': 210137, 'rank': 2, 'score': 0.6186076998710632}, {'query_id': 'Q01', 'doc_id': 198900, 'rank': 3, 'score': 0.6012340784072876}, {'query_id': 'Q01', 'doc_id': 199915, 'rank': 4, 'score': 0.60053950548172}, {'query_id': 'Q01', 'doc_id': 206230, 'rank': 5, 'score': 0.5959801077842712}, {'query_id': 'Q01', 'doc_id': 193836, 'rank': 6, 'score': 0.5952180624008179}, {'query_id': 'Q01', 'doc_id': 193373, 'rank': 7, 'score': 0.5912319421768188}, {'query_id': 'Q01', 'doc_id': 193715, 'rank': 8, 'score': 0.5833245515823364}, {'query_id': 'Q01', 'doc_id': 193375, 'rank': 9, 'score': 0.5811315774917603}, {'query_id': 'Q01', 'doc_id': 206011, 'rank': 10, 'score': 0.5733577013015747}, {'query_id': 'Q01', 'doc_id': 194890, 'rank': 11, 'score': 0.569999098777771}, {'query_id': 'Q01', 'doc_id': 206228, 'rank': 12, 'score': 0.5632987022399902}, {'query_id': 'Q01', 'doc_id': 204144, 'rank': 13, 'score': 0.5615097880363464}, {'query_id': 'Q01', 'doc_id': 210133, 'rank': 14, 'score': 0.5613101124763489}]]
```

Στην συνέχεια, οι λίστες με τα αποτελέσματα αποθηκεύονται σε αρχεία `txt` για να χρησιμοποιηθούν στο `trec_eval`, με την παρακάτω μορφή.

```
!python3 -c "
with open('run_faiss_k20.txt') as file:
    print(file.read())
"
```

```
Q01 Q0 193378 1 0.9309734106063843 run_faiss_k20
Q01 Q0 210137 2 0.6186076998710632 run_faiss_k20
Q01 Q0 198900 3 0.6012340784072876 run_faiss_k20
Q01 Q0 199915 4 0.60053950548172 run_faiss_k20
Q01 Q0 206230 5 0.5959801077842712 run_faiss_k20
Q01 Q0 193836 6 0.5952180624008179 run_faiss_k20
Q01 Q0 193373 7 0.5912319421768188 run_faiss_k20
Q01 Q0 193715 8 0.5833245515823364 run_faiss_k20
Q01 Q0 193375 9 0.5811315774917603 run_faiss_k20
Q01 Q0 206011 10 0.5733577013015747 run_faiss_k20
Q01 Q0 194890 11 0.569999098777771 run_faiss_k20
Q01 Q0 206228 12 0.5632987022399902 run_faiss_k20
Q01 Q0 204144 13 0.5615097880363464 run_faiss_k20
Q01 Q0 210133 14 0.5613101124763489 run_faiss_k20
```

5. Αξιολογήστε τα αποτελέσματά σας συγκρίνοντάς τα με τις σωστές απαντήσεις χρησιμοποιώντας το εργαλείο αξιολόγησης `trec_eval` και τα μέτρα αξιολόγησης *MAP* (*mean average precision*) και *Precision@k* (μέση ακρίβεια στα *k* πρώτα ανακτηθέντα κείμενα) για *k* = 5, 10, 15, 20.

Μετακινούμε τα 3 αρχεία που δημιουργήθηκαν στον φάκελο με το εργαλείο `trec_eval`.

Αρχικά εκτελούμε την εντολή `>trec_eval -q qrels.txt run_faiss_k20.txt` για να πάρουμε τα αποτελέσματα της αξιολόγησης στα **k=20 κείμενα**.

Μετά `>trec_eval -q qrels.txt run_faiss_k30.txt` για **k=30 κείμενα** και `>trec_eval -q qrels.txt run_faiss_k50.txt` για **k=50 κείμενα**.

map	all	0.3129
gm_map	all	0.2914
Rprec	all	0.3909
bpref	all	0.4447
recip_rank	all	0.9500
iprec_at_recall_0.00	all	0.9556
iprec_at_recall_0.10	all	0.8206
iprec_at_recall_0.20	all	0.7535
iprec_at_recall_0.30	all	0.5257
iprec_at_recall_0.40	all	0.3854
iprec_at_recall_0.50	all	0.2354
iprec_at_recall_0.60	all	0.0684
iprec_at_recall_0.70	all	0.0000
iprec_at_recall_0.80	all	0.0000
iprec_at_recall_0.90	all	0.0000
iprec_at_recall_1.00	all	0.0000
P_5	all	0.6600
P_10	all	0.5000
P_15	all	0.3933
P_20	all	0.3500
P_30	all	0.2333
P_100	all	0.0700
P_200	all	0.0350
P_500	all	0.0140
P_1000	all	0.0070

Εικόνα 1: k=20

map	all	0.3413
gm_map	all	0.3194
Rprec	all	0.3909
bpref	all	0.5320
recip_rank	all	0.9500
iprec_at_recall_0.00	all	0.9556
iprec_at_recall_0.10	all	0.8206
iprec_at_recall_0.20	all	0.7559
iprec_at_recall_0.30	all	0.5439
iprec_at_recall_0.40	all	0.4075
iprec_at_recall_0.50	all	0.3572
iprec_at_recall_0.60	all	0.1429
iprec_at_recall_0.70	all	0.0000
iprec_at_recall_0.80	all	0.0000
iprec_at_recall_0.90	all	0.0000
iprec_at_recall_1.00	all	0.0000
P_5	all	0.6600
P_10	all	0.5000
P_15	all	0.3933
P_20	all	0.3500
P_30	all	0.2767
P_100	all	0.0830
P_200	all	0.0415
P_500	all	0.0166
P_1000	all	0.0083

Εικόνα 2: k=30

map	all	0.3744
gm_map	all	0.3501
Rprec	all	0.3909
bpref	all	0.6626
recip_rank	all	0.9500
iprec_at_recall_0.00	all	0.9556
iprec_at_recall_0.10	all	0.8206
iprec_at_recall_0.20	all	0.7559
iprec_at_recall_0.30	all	0.5439
iprec_at_recall_0.40	all	0.4394
iprec_at_recall_0.50	all	0.3724
iprec_at_recall_0.60	all	0.2623
iprec_at_recall_0.70	all	0.1561
iprec_at_recall_0.80	all	0.0672
iprec_at_recall_0.90	all	0.0000
iprec_at_recall_1.00	all	0.0000
P_5	all	0.6600
P_10	all	0.5000
P_15	all	0.3933
P_20	all	0.3500
P_30	all	0.2767
P_100	all	0.1030
P_200	all	0.0515
P_500	all	0.0206
P_1000	all	0.0103

Εικόνα 3: k=50

Καταλήγουμε σε αυτόν τον πίνακα αποτελεσμάτων:

k	20	30	50
map	0.3129	0.3413	0.3744
P_5	0.6600	0.6600	0.6600
P_10	0.5000	0.5000	0.5000
P_15	0.3933	0.3933	0.3933
P_20	0.3500	0.3500	0.3500
P_30	0.2333	0.2767	0.2767
P_100	0.0700	0.0830	0.1030
P_200	0.0350	0.0415	0.0515
P_500	0.0140	0.0166	0.0206
P_1000	0.0070	0.0083	0.0103

Παρατηρούμε ότι το MAP (mean average precision) αυξάνεται καθώς αυξάνεται το πλήθος των ανακτηθέντων κειμένων k. Συγκεκριμένα το map αυξάνεται από 0.3129 για k=20, σε 0.3413 για k=30 και σε 0.3744 για k=50. Η μεγαλύτερη αύξηση εμφανίζεται από τα 30 στα 50 κείμενα ($0.3744 - 0.3413 = 0.0331$), ενώ από τα 20 στα 30 κείμενα η βελτίωση είναι μικρότερη ($0.3413 - 0.3129 = 0.0284$).

Βλέπουμε ότι για σταθερό πλήθος ανακτηθέντων κειμένων η ακρίβεια (precision) μειώνεται όσο αυξάνεται το k, που είναι λογικό αφού μπαίνουν όλο και περισσότερα μη συναφή κείμενα στην ανάκτηση. Το Precision@k για k μέχρι 20 κείμενα παραμένει σταθερό για τα πρώτα 20,30 και 50 ανακτηθέντα κείμενα, συμπεραίνοντας ότι το σύστημα ανακτά τα συναφή έγγραφα νωρίς και ότι η κατάταξη των ανακτηθέντων εγγράφων είναι σταθερή για τα 20 πρώτα.

Μπορούμε να συμπεράνουμε ότι το σύστημα σημασιολογικής ανάκτησης που φτιάξαμε έχει καλή ακρίβεια, με MAP γύρω στο 35% στα πρώτα αποτελέσματα. Οι τιμές του Precision@5 μέχρι Precision@20 είναι σταθερές και ανεξάρτητες του πλήθους των ανακτηθέντων κειμένων, κάτι που δείχνει ότι η κατάταξη στα κορυφαία αποτελέσματα είναι σταθερή και άρα αξιόπιστη. Γενικά, η αύξηση που MAP αν και φθίνουσα υποδεικνύει ότι το σύστημα συνεχίζει να ανακτά συναφή κείμενα και σε χαμηλότερη κατάταξη.

Τελικά, παρόλο που οι τιμές του MAP κυμαίνονται γύρω στο 35% αυτό είναι αναμενόμενο και ικανοποιητικό για σύστημα σημασιολογικής ανάκτησης, αφού η συνάφεια δεν βασίζεται στην απλή ταύτιση λέξεων αλλά στην σημασιολογική ομοιότητα και χρησιμοποιήσαμε προεκπαιδευμένο μοντέλο. Επιπλέον, οι ψηλές τιμές στο precision

στα $k=5$, $k=10$ κείμενα δείχνει πως το σύστημα μας κατατάσσει τα πιο σχετικά κείμενα στις πρώτες θέσεις, κάτι που αποτελεί βασικό στόχο.

6. Σύγκριση αποτελεσμάτων Φάσης 1 με αποτελέσματα Φάσης 2.

	Φάση 1	Φάση 2
MAP		
k= 20	0.6895	0.3129
k=30	0.7471	0.3413
k=50	0.7701	0.3744
Precision		
P_5	0.88	0.66
P_10	0.73	0.5
P_15	0.7	0.3933
P_20	0.63	0.35

Παρατηρούμε ότι η κλασική ανάκτηση στην Φάση 1 έχει πιο υψηλές τιμές στα μέτρα αξιολόγησης MAP και Precision σε σχέση με την σημασιολογική ανάκτηση στην Φάση 2. Συγκεκριμένα η μέση ακρίβεια map φτάνει περίπου έως και 0.77 για $k=50$ στην πρώτη φάση, ενώ στην δεύτερη φτάνει μόνο μέχρι 0.37 για $k=50$ αντίστοιχα. Παρόμοια, το precision@5 στην φάση 1 είναι 0.88, σε αντίθεση με το 0.66 στην φάση 2.

Αυτή η μείωση των τιμών των μετρικών δεν σημαίνει αυτομάτως πως το σύστημα της δεύτερης φάσης είναι κατώτερο, αφού συγκρίνουμε διαφορετικές προσεγγίσεις.

Η κλασική ανάκτηση της πρώτης φάσης βασίζεται στην ταύτιση των λέξεων/όρων μεταξύ ερωτήματος και κειμένου, δηλαδή αν ένα κείμενο περιέχει τους όρους του ερωτήματος τότε θα λάβει υψηλό σκορ ομοιότητας και θεωρείται συναφές. Αυτό οδηγεί σε υψηλότερη ακρίβεια ειδικά όταν τα ερωτήματα αφορούν λεξική συνάφεια.

Από την άλλη, η σημασιολογική ανάκτηση της δεύτερης φάσης βασίζεται στο νόημα του κειμένου και όχι στις λέξεις μεμονωμένα. Αυτό σημαίνει ότι μπορεί να επιστρέψει κείμενα που είναι σημασιολογικά σχετικά αλλά να μην περιέχουν τους ίδιους όρους. Το μοντέλο από τη βιβλιοθήκη transformers που χρησιμοποιήσαμε είναι προεκπαιδευμένο, δηλαδή δεν έχει εκπαιδευτεί ειδικά για την συγκεκριμένη συλλογή κειμένων, όμως το αποτέλεσμα του MAP = 35% είναι ικανοποιητικό.

Ελέγχοντας μόνο τα αποτελέσματα των μετρικών φαίνεται πως δεν υπάρχει βελτίωση στο σύστημα της δεύτερης φάσης, όμως αυτό το σύστημα δεν έχει στόχο την λεξική ταύτιση των κειμένων αλλά στην σημασιολογική συνάφεια μεταξύ τους, προσφέροντας ένα ευρύτερο φάσμα ανακτηθέντων κειμένων.

Συνολικά, παρόλο που η κλασική ανάκτηση καταγράφει υψηλότερες τιμές ακρίβειας, η σημασιολογική ανάκτηση προσφέρει μια διαφορετική προσέγγιση στην ανάκτηση κειμένων βάσει του νοήματός του περιεχομένου τους. Τα αποτελέσματα της φάσης 2 είναι ικανοποιητικά, δεδομένου ότι χρησιμοποιήσαμε προεκπαιδευμένο μοντέλο χωρίς κάποια προσαρμογή στα δεδομένα μας, ενώ παράλληλα η σταθερότητα στα κορυφαία αποτελέσματα δείχνει ότι το σύστημα είναι αξιόπιστο. Καταλαβαίνουμε πως η χρήση του ενός συστήματος έναντι του άλλου εξαρτάται από το είδος και τις απαιτήσεις της εφαρμογής.

Τελικά, λαμβάνοντας λοιπόν υπόψη τα αποτελέσματα αξιολόγησης με βάση την συλλογή IR2025 και τα ερωτήματα (queries) μπορούμε να συμπεράνουμε ότι στην περίπτωσή μας η κλασική ανάκτηση παρουσιάζει καλύτερη απόδοση σε σχέση με την σημασιολογική ανάκτηση. Τα ερωτήματα είναι περιγραφικά και μεγάλα σε έκταση, περιλαμβάνοντας εξειδικευμένες λέξεις που εμφανίζονται αυτούσιες στα συναφή κείμενα. Αυτό επιφέρει καλύτερα αποτελέσματα με την κλασική ανάκτηση που κάνει αντιστοίχιση όρων. Αντίθετα, η σημασιολογική ανάκτηση μπορεί να οδηγήσει στην ανάκτηση κειμένων τα οποία έχουν σχετικό θέμα αλλά δεν θεωρούνται σχετικά σύμφωνα με τα αποτελέσματα qrels, κάτι που δικαιολογεί τις χαμηλότερες τιμές στις μετρικές.